

# Symulacja rozprzestrzeniania się chorób w populacji z wykorzystaniem modelu agentowego

Wojciech Niemiec

Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie

Wydział Informatyki

wnagh@student.agh.edu.pl

2026

## Streszczenie

W pracy przedstawiono agentowy model symulacji rozprzestrzeniania się chorób zakaźnych, oparty na rozszerzeniu klasycznego modelu SIR. Model uwzględnia sześć stanów agentów: podatny (S – susceptible), zarażony (I – infected), odporny (R – recovered), zmarły (D – dead), zaszczepiony (V – vaccinated) oraz poddany kwarantannie (Q – quarantined). Parametry dobrano na podstawie danych dotyczących pandemii COVID-19, przyjmując Nową Zelandię jako punkt odniesienia dla parametrów interwencji. Przeprowadzono cztery eksperymenty badające wpływ współczynnika zaraźliwości, strategii interwencji, tempa kampanii szczepień oraz struktury wiekowej populacji na przebieg epidemii. Symulacje wykonano w języku Python z użyciem biblioteki Mesa.

**Słowa kluczowe:** model agentowy, symulacja epidemii, SIR, COVID-19, Mesa, Python

## 1 Wstęp i przegląd aktualnego stanu badań

Modelowanie epidemii chorób zakaźnych jest jednym z podstawowych narzędzi epidemiologii. Klasyczne modele kompartmentowe, takie jak model SIR zaproponowany przez Kermacka i McKendricka [1], opisują przebieg epidemii za pomocą układów równań różniczkowych, dzieląc populację na grupy według stanu zdrowotnego. Podejście to, choć poprawne matematycznie, traktuje populację jako jednorodną całość i nie uwzględnia indywidualnych mechanizmów interwencji, takich jak izolacja pojedynczych osób czy selektywne szczepienia.

Modele agentowe pozwalają symulować zachowania poszczególnych jednostek i ich lokalne interakcje [2]. Każdy agent reprezentuje konkretną osobę, ma przypisany stan zdrowotny oraz indywidualne cechy wpływające na przebieg choroby. Takie podejście umożliwia uwzględnienie różnorodności populacji i losowości kontaktów społecznych, co jest trudne do osiągnięcia w modelach klasycznych.

Podczas pandemii COVID-19 modele symulacyjne okazały się istotnym narzędziem wspierającym decyzje zdrowotne. Raport Imperial College London [3] pokazał, że pozwalają oceniać skuteczność różnych strategii interwencji jeszcze przed ich wdrożeniem. Jako punkt odniesienia dla parametrów interwencji wybrano Nową Zelandię – kraj, który łącząc obowiązkową kwarantannę z intensywną kampanią szczepień osiągnął poziom wyszczepienia sięgający 90% uprawnionych do końca 2021 roku [4].

Celem pracy jest implementacja rozszerzonego modelu agentowego epidemii i analiza wpływu wybranych parametrów epidemiologicznych oraz strategii interwencji na przebieg symulacji. Model zaimplementowano w Pythonie z użyciem biblioteki Mesa [5].

Raport zorganizowany jest następująco. Sekcja 2 opisuje strukturę modelu i przyjęte założenia. Sekcja 3 przedstawia wyniki czterech eksperymentów. Sekcja 4 zawiera wnioski i kierunki dalszych badań.

## 2 Opis modelu agentowego

### 2.1 Opis modelu i logika agenta

Do wykonania eksperymentów użyto modelowania opartego na agentach (ABM – Agent-Based Model), które rozszerza standardowe modele epidemiologiczne o możliwość przypisania każdej jednostce indywidualnych cech i zachowań. Użyty model wyróżnia sześć stanów agenta:

- podatny (S – susceptible),
- zarażony (I – infected),
- odporny (R – recovered),
- zmarły (D – dead),
- zaszczepiony (V – vaccinated),
- poddany kwarantannie (Q – quarantined).

Klasyczny model SIR został rozszerzony o trzy dodatkowe stany. Każdy agent posiada trzy atrybuty: stan zdrowotny, grupę wiekową (młody, dorosły, senior) oraz licznik dni pozostałych do końca kwarantanny (domyślnie zero). Przyjęto uproszczony rozkład grup wiekowych 20/60/20 jako przybliżenie struktury typowej populacji.

Grupa wiekowa wpływa na dwa parametry: tempo zdrowienia  $\gamma$  oraz prawdopodobieństwo śmierci  $\delta$ . Dla grupy młodych parametry te są mnożone odpowiednio przez 2.0 i 0.1, natomiast dla seniorów przez 0.6 i 3.0. Wartości dla grupy dorosłych pozostają bez zmian. Przyjęto założenie, że seniorzy mają istotnie wyższe ryzyko zgonu w wyniku choroby, co jest zgodne z danymi epidemiologicznymi dotyczącymi COVID-19 – Levin et al. [6] wykazali, że współczynnik IFR rośnie wykładniczo z wiekiem, osiągając wartość ponad 4% dla osób po 75. roku życia wobec poniżej 0.01% dla młodych dorosłych. Wolniejsze zdrowienie seniorów wynika z gorszej ogólnej kondycji układu odpornościowego.

W badanym modelu agent to obiekt systemu posiadający unikalne ID, atrybut opisujący grupę wiekową oraz stan zdrowotny. Agenci rozmieszczeni są na siatce o rozmiarach  $40 \times 40$  pól w eksperymentach właściwych. Wiele agentów może jednocześnie zajmować to samo pole.

W każdej turze symulacji agent wykonuje akcje zależne od swojego aktualnego stanu. Agent w stanie D (zmarły) nie wykonuje żadnych akcji. Agent w stanie Q (kwarantanna) nie porusza się ani nie zaraża sąsiadów – odczekuje przypisaną liczbę dni, po czym wraca do stanu I i może ponownie wyzdrowieć lub umrzeć. Pozostałe stany wykonują następujące akcje:

- **Ruch** – agent przemieszcza się na losowo wybrane sąsiadujące pole spośród ośmiu możliwych kierunków, zgodnie z sąsiedztwem Moore’a.

- **Zarażanie sąsiadów** – chory agent podejmuje próbę zarażenia agentów na sąsiadujących polach. Podatny agent (S) zostaje zarażony z prawdopodobieństwem  $\beta$ . Zaszczepiony agent (V) może zostać zarażony z prawdopodobieństwem  $\beta \cdot (1 - \varepsilon)$ , gdzie  $\varepsilon$  oznacza skuteczność szczepionki – przyjęto założenie, że szczepionka zmniejsza ryzyko zarażenia, lecz nie eliminuje go całkowicie.
- **Zdrowienie lub zgon** – na podstawie rozkładu losowego oraz parametrów  $\delta$  i  $\gamma$  (skorygowanych o grupę wiekową) stan chorego agenta może zmienić się na R (odporny) lub D (zmarły). Parametr  $\delta$  jest sprawdzany jako pierwszy – jeśli agent umiera, parametr  $\gamma$  nie jest już sprawdzany.
- **Kwarantanna** – z prawdopodobieństwem  $q$  zarażony agent zostaje skierowany na kwarantannę, zmieniając stan na Q. Przez czas trwania kwarantanny agent pozostaje nieruchomy i nie zaraża sąsiadów.

## 2.2 Parametry modelu

Parametry modelu oparto na kilku niezależnych publikacjach naukowych. Ich wartości przedstawia Tabela 1, a uzasadnienie znajduje się poniżej.

Tabela 1: Parametry bazowe modelu

| Parametr                   | Symbol        | Wartość        |
|----------------------------|---------------|----------------|
| Współczynnik zaraźliwości  | $\beta$       | 0.08           |
| Tempo zdrowienia           | $\gamma$      | 0.07           |
| Współczynnik śmiertelności | $\delta$      | 0.001          |
| Skuteczność szczepionki    | $\varepsilon$ | 0.84           |
| Tempo szczepień            | $v$           | 0.00           |
| Czas kwarantanny           | $q$           | 10             |
| Prawdop. kwarantanny       | $\rho$        | 0.00           |
| Liczba agentów             | $N$           | 1000           |
| Rozmiar siatki             | —             | $40 \times 40$ |

Współczynnik zaraźliwości  $\beta$ , tempo zdrowienia  $\gamma$  oraz współczynnik śmiertelności  $\delta$  dobrano na podstawie estymacji modelu SIRD dla danych epidemiologicznych Zjednoczonego Królestwa z okresu kwiecień 2020 – wrzesień 2021 [7]. Autorzy wyestymowali parametry modelu metodą state-space z wykorzystaniem filtra Kalmana, kalibrując model na rzeczywistych danych o przypadkach i zgonach.

Skuteczność szczepionki  $\varepsilon = 0.84$  przyjęto na podstawie badania CDC obejmującego dorosłych hospitalizowanych z powodu COVID-19 w Stanach Zjednoczonych – skuteczność szczepionek Pfizer-BioNTech i Moderna wyniosła 84% w okresie 13–24 tygodni po przyjęciu drugiej dawki [8].

Czas kwarantanny  $q = 10$  dni uzasadniają badania empiryczne przeprowadzone na czterech kohortach uniwersyteckich – Liu et al. [9] wykazali, że kwarantanna oparta na testach PCR powinna wynosić właśnie 10 dni, aby utrzymać ryzyko transmisji po jej zakończeniu poniżej 5%.


Parametry  $v$  i  $\rho$  dotyczące szczepień i kwarantanny przyjęto domyślnie jako zero, ponieważ stanowią zmienne eksperymentalne badane w rozdziale 3. Liczba agentów  $N = 1000$  oraz rozmiar siatki  $40 \times 40$  to parametry techniczne przyjęte jako uproszczenie obliczeniowe.

## 2.3 Implementacja

Projekt zaimplementowano w języku Python 3.13 z wykorzystaniem biblioteki Mesa [5] w wersji 2.3.0. Do analizy i wizualizacji wyników eksperymentów użyto bibliotek pandas, numpy oraz matplotlib. Interaktywna wizualizacja oparta jest na bibliotece mesa-viz-tornado. Projekt składa się z następujących plików:

```
1 disease_simulation/
2 |-- simulation/
3 |   |-- agent.py          # agent logic
4 |   |-- model.py          # model and grid
5 |   - visualization.py    visualization server|- experiments/|- experiments.py batch
   experiments|- figures/  output charts'- report/ LaTeX report
```

Interaktywna wizualizacja umożliwia przeprowadzenie symulacji z dowolnie wybranymi parametrami oraz obserwację wyników w czasie rzeczywistym w przeglądarce internetowej. Panel boczny zawiera suwaki pozwalające na modyfikację wszystkich parametrów modelu bez konieczności ingerencji w kod źródłowy. Przykładowy widok wizualizacji przedstawia Rysunek 1.




Rysunek 1: Widok interaktywnej wizualizacji symulacji. Po lewej stronie panel z suwakami parametrów, po prawej siatka agentów (niebieski – podatny, czerwony – zarażony, zielony – odporny, czarny – zmarły, fioletowy – zaszczepiony, pomarańczowy – kwarantanna) oraz wykres stanów SIRDVQ w czasie rzeczywistym.

Eksperymenty uruchamiane są z pliku `experiments.py` i obejmują cztery pętle oparte na bazowych parametrach oraz na zmienianych wartościach poszczególnych zmiennych w celu zbadania różnych scenariuszy epidemii. Zakres obejmuje 300 dni od pierwszego zakażenia. Aby utrzymać stabilność wyników, każdą pętlę wykonano 30 razy i wyciągnięto średnią i odchylenie standardowe.

### 3 Wyniki badań eksperymentalnych

#### 3.1 Eksperyment 1 – Wpływ współczynnika zaraźliwości

Eksperyment bada wpływ współczynnika zaraźliwości  $\beta$  na rozwój i przebieg epidemii przy wyłączonych interwencjach, zgodnie z zasadą *ceteris paribus*. Pozostałe parametry przyjmują wartości bazowe z Tabeli 1.



Rysunek 2: Wpływ współczynnika zaraźliwości  $\beta$  na przebieg epidemii. Kolory odpowiadają wartościom  $\beta \in \{0.02, 0.05, 0.08, 0.12, 0.20\}$ . Zacieniowane obszary reprezentują odchylenie standardowe z 30 uruchomień.


Pierwszy wykres pokazuje liczbę zarażonych przy różnych wartościach  $\beta$ . Wynik jest zgodny z oczekiwaniami – im wyższa zaraźliwość, tym szybciej osiągnany jest szczyt zachorowań i tym krócej trwa epidemia. Przypadek  $\beta = 0.02$  jest szczególny – choroba nie osiągnęła wystarczającej zaraźliwości, aby rozprzestrzenić się w całej populacji, co skutkowało minimalną liczbą zachorowań i samoistnym wygaszeniem epidemii.

Drugi wykres przedstawia nabywanie odporności przy założeniu braku kampanii szczepień. Dla wartości  $\beta \geq 0.05$  już około 50. dnia znacząca większość populacji nabywa odporność naturalną. Ponownie wyróżnia się przypadek  $\beta = 0.02$  – widoczne jest tu znacznie większe odchylenie standardowe względem pozostałych wariantów, co wynika z wysokiej losowości przy tak niskim współczynniku zaraźliwości.

Trzeci wykres przedstawia łączną liczbę zgonów. W porównaniu do poprzednich wykresów odchylenie standardowe jest wysokie we wszystkich wariantach – jest to efekt małego prawdopodobieństwa zgonu  $\delta$ , przy którym losowość ma duży wpływ na wynik. Interesującą obserwacją jest zbliżona śmiertelność dla  $\beta \geq 0.08$ , pomimo różnic w szczycie zachorowań. Wynika to z tzw. efektu wyczerpania populacji podatnej (*burnout effect*) – przy bardzo wysokiej zaraźliwości epidemia przebiega tak gwałtownie, że chorzy zdrowieją lub umierają zanim zdążą zarażić kolejne osoby, co paradoksalnie ogranicza łączną liczbę zgonów względem wariantów o umiarkowanej zaraźliwości.

#### 3.2 Eksperyment 2 – Porównanie strategii interwencji

Eksperyment porównuje cztery scenariusze interwencji: brak działań, sama kwarantanna, same szczepienia oraz połączenie obu metod. Parametry interwencji oparto na danych z Nowej Zelandii [4] – tempo szczepień wynosi 0.3%/dzień, prawdopodobieństwo kwarantanny  $\rho = 0.3$ , czas izolacji  $q = 10$  dni.



Rysunek 3: Porównanie strategii interwencji: brak interwencji, sama kwarantanna, same szczepienia oraz połączenie obu metod. Zacięte obszary reprezentują odchylenie standardowe z 30 uruchomień.


Pierwszy wykres pokazuje wyraźne różnice w liczbie zarażonych między scenariuszami. Brak interwencji i same szczepienia dają podobny szczyt zachorowań – szczepienia przy tempie 0.3%/dzień nie nadążają za rozprzestrzenianiem się epidemii w wczesnej fazie. Kwarantanna natomiast niemal całkowicie eliminuje zachorowania, co wynika z założeń modelowych – agent objęty kwarantanną jest w pełni izolowany i nie zaraża sąsiadów. W rzeczywistości skuteczność izolacji jest niższa ze względu na nieprzestrzeganie zasad i kontakty domowe, co stanowi ograniczenie modelu.

Drugi wykres pokazuje nabytą odporność. Scenariusz bez interwencji i ze szczepieniami osiągają wysoką odporność populacyjną przez naturalne przechorowanie – odpowiednio około 950 i 850 agentów. Przy samej kwarantannie liczba odpornych jest bardzo niska, co oznacza że epidemia jest kontrolowana, ale populacja pozostaje podatna – potencjalnie narażona na kolejną falę po zniesieniu restrykcji.

Trzeci wykres potwierdza że połączenie kwarantanny i szczepień niemal eliminuje zgony. Sama kwarantanna redukuje je znacząco, natomiast same szczepienia przy przyjętym tempie kampanii dają efekt zbliżony do braku interwencji – co sugeruje, że przy  $\beta = 0.08$  tempo 0.3%/dzień jest niewystarczające do skutecznej ochrony populacji bez wsparcia izolacji.

### 3.3 Eksperyment 3 – Wpływ tempa kampanii szczepień

Eksperyment bada jak tempo szczepień wpływa na przebieg epidemii. Wartość 0.3%/dzień odpowiada średniemu tempu kampanii w Nowej Zelandii [4], pozostałe wartości stanowią scenariusze porównawcze.



Rysunek 4: Wpływ tempa kampanii szczepień na przebieg epidemii. Wartość 0.3%/dzień odpowiada średniemu tempu kampanii w Nowej Zelandii [4]. Zacieniowane obszary reprezentują odchylenie standardowe z 30 uruchomień.

Pierwszy wykres pokazuje że szczepienia przy tempie poniżej 0.7%/dzień mają ograniczony wpływ na szczyt zachorowań – krzywe zarażonych dla wariantów 0.1%, 0.3% i braku szczepień są zbliżone. Dopiero agresywna kampania 1.5%/dzień wyraźnie obniża szczyt i skraca czas trwania epidemii.

Drugi wykres potwierdza tę obserwację – przy tempie 1.5%/dzień populacja jest szczepiona tak szybko, że znaczna jej część nabywa odporność przed kontaktem z chorym. Dla pozostałych wariantów liczba zaszczepionych stabilizuje się na niskim poziomie, bo epidemia wygasa zanim kampania zdąży objąć większość populacji.

Trzeci wykres pokazuje że redukcja zgonów jest widoczna dopiero przy tempie 0.7%/dzień i wyższym. Przy tempie odpowiadającym Nowej Zelandii (0.3%/dzień) różnica względem braku szczepień jest minimalna – co sugeruje że sama kampania szczepień bez wsparcia kwarantanną jest niewystarczająca przy przyjętych parametrach bazowych.

### 3.4 Eksperyment 4 – Wpływ struktury wiekowej populacji

Eksperyment bada jak zmiana proporcji grup wiekowych wpływa na śmiertelność i szczyt zachorowań. Trzy scenariusze odpowiadają populacji młodej (70/20/10), przeciętnej (20/60/20) oraz starzejącej się (10/50/40).



Rysunek 5: Wpływ struktury wiekowej na śmiertelność i szczyt zachorowań. Słupki błędów reprezentują odchylenie standardowe z 30 uruchomień.

Pierwszy wykres pokazuje wyraźny wzrost śmiertelności wraz ze starzeniem się populacji – od około 1% dla populacji młodej do prawie 4% dla starzejącej się. Wynik jest zgodny z danymi



epidemiologicznymi – Levin et al. [6] wykazali że śmiertelność COVID-19 rośnie wykładniczo z wiekiem. Warto jednak zauważyć że odchylenie standardowe jest stosunkowo duże, co wynika z losowości przydziału grup wiekowych w każdym uruchomieniu.

Drugi wykres pokazuje że szczyt zachorowań również rośnie wraz ze starzeniem się populacji, choć różnica między scenariuszem przeciętnym a starzejącym się jest niewielka. Wynika to z faktu że parametr  $\beta$  jest jednakowy dla wszystkich grup wiekowych – wiek wpływa na śmiertelność i tempo zdrowienia, ale nie na samą zaraźliwość agentów.

## 4 Podsumowanie i wnioski

Przeprowadzone eksperymenty pozwoliły na analizę wpływu kluczowych parametrów epidemiologicznych na przebieg symulacji agentowej.

Współczynnik zaraźliwości  $\beta$  ma istotny wpływ na dynamikę epidemii – wyższe wartości przyspieszają szczyt zachorowań i skracają czas trwania epidemii. Zaobserwowano jednak tzw. *burnout effect*: przy bardzo wysokiej zaraźliwości łączna śmiertelność może być niższa niż przy wartościach umiarkowanych, ponieważ epidemia wygasa zanim zdąży objąć całą podatną populację.

Strategie interwencyjne są wyraźnie skuteczne w ograniczaniu liczby zachorowań i zgonów. Najefektywniejsza okazała się kwarantanna oraz połączenie kwarantanny ze szczepieniami. Należy jednak zaznaczyć ograniczenie modelu – w rzeczywistości idealna izolacja jest trudna do osiągnięcia ze względu na kontakty domowe i nieprzestrzeganie zasad, co oznacza że rzeczywista skuteczność kwarantanny byłaby niższa niż wynika z symulacji.

Tempo kampanii szczepień ma mierzalny wpływ na przebieg epidemii, jednak redukcja zgonów staje się wyraźna dopiero przy agresywnych wariantach kampanii – 0.7% populacji dziennie i więcej. Tempo odpowiadające danym z Nowej Zelandii (0.3%/dzień) bez wsparcia kwarantanną okazało się niewystarczające przy przyjętych parametrach bazowych.

Struktura wiekowa populacji istotnie wpływa na śmiertelność – w populacji starzejącej się jest ona niemal czterokrotnie wyższa niż w młodej. Szczyt zachorowań jest natomiast stosunkowo podobny dla populacji przeciętnej i starzejącej się, co wynika z faktu że wiek nie wpływa na zaraźliwość agentów, a jedynie na tempo zdrowienia i prawdopodobieństwo zgonu.

Dalsze badania mogłyby uwzględnić bardziej realistyczny model kwarantanny z niepełną izolacją, wprowadzenie reinfection (powrotu odpornych do puli podatnych) oraz kalibrację modelu do konkretnych danych czasowych z wybranego kraju.

## Bibliografia

- [1] W. O. Kermack i A. G. McKendrick. „A Contribution to the Mathematical Theory of Epidemics”. W: *Proceedings of the Royal Society of London. Series A* 115.772 (1927), s. 700–721. DOI: [10.1098/rspa.1927.0118](https://doi.org/10.1098/rspa.1927.0118).
- [2] S. F. Railsback i V. Grimm. *Agent-Based and Individual-Based Modeling: A Practical Introduction*. Princeton, NJ: Princeton University Press, 2011.
- [3] N. M. Ferguson, D. Laydon, G. Nedjati-Gilani, N. Imai, K. Ainslie, M. Baguelin, S. Bhatia, A. Boonyasiri, Z. Cucunubá, G. Cuomo-Dannenburg i in. *Impact of Non-Pharmaceutical Interventions (NPIs) to Reduce COVID-19 Mortality and Healthcare Demand*. Spraw. tech. Imperial College London, 2020. DOI: [10.25561/77482](https://doi.org/10.25561/77482).



- 
- [4] M. G. Baker, A. Kvalsvig i A. J. Verrall. „New Zealand’s COVID-19 Elimination Strategy”. W: *Medical Journal of Australia* 213.5 (2020), s. 198–200. DOI: [10.5694/mja2.50735](https://doi.org/10.5694/mja2.50735).
- [5] J. Kazil, D. Masad i A. Crooks. „Utilizing Python for Agent-Based Modeling: The Mesa Framework”. W: *Social, Cultural, and Behavioral Modeling. SBP-BRiMS 2020*. T. 12268. Lecture Notes in Computer Science. Cham: Springer, 2020, s. 308–317. DOI: [10.1007/978-3-030-61255-9\\_30](https://doi.org/10.1007/978-3-030-61255-9_30).
- [6] A. T. Levin, W. P. Hanage, N. Owusu-Boaitey, K. B. Cochran, S. P. Walsh i G. Meyerowitz-Katz. „Assessing the Age Specificity of Infection Fatality Rates for COVID-19: Systematic Review, Meta-Analysis, and Public Policy Implications”. W: *European Journal of Epidemiology* 35 (2020), s. 1123–1138. DOI: [10.1007/s10654-020-00698-1](https://doi.org/10.1007/s10654-020-00698-1).
- [7] A. P. Alencar i in. „Forecasting Covid-19 in the United Kingdom: A dynamic SIRD model”. W: *PLOS ONE* 17.8 (2022), e0271577. DOI: [10.1371/journal.pone.0271577](https://doi.org/10.1371/journal.pone.0271577).
- [8] M. W. Tenforde i in. „Sustained Effectiveness of Pfizer-BioNTech and Moderna Vaccines Against COVID-19 Associated Hospitalizations Among Adults — United States, March–July 2021”. W: *Morbidity and Mortality Weekly Report* 70.34 (2021), s. 1156–1162. DOI: [10.15585/mmwr.mm7034e2](https://doi.org/10.15585/mmwr.mm7034e2).
- [9] A. B. Liu i in. „Association of COVID-19 Quarantine Duration and Postquarantine Transmission Risk in 4 University Cohorts”. W: *JAMA Network Open* 5.2 (2022), e220088. DOI: [10.1001/jamanetworkopen.2022.0088](https://doi.org/10.1001/jamanetworkopen.2022.0088).